



TAREA: LIMPIEZA DE DATOS INCOHERENTES DE UNA BASE DE DATOS PARA OBTENER UNA MEJOR PRECISION Y UN ARBOL DE DECISION MUCHO MEJOR ESTRUCTURADO

ALFARO VICTORIA GINO PAOLI


PASO 1: Abrimos la data Diabetes




Paso 2: Usamos el 80 % de los datos



Paso 3: Ponemos "start" y visualizamos la matriz de confusión



Paso 4: Seguimos los pasos hechos en clase para poder visualizar el árbol de decisión



Paso 5: Limpieza de datos ya que existen datos que indican que hay personas con presión cero (**se analizan personas literalmente muertas**)

Viewer

Relation: pima_diabetes

No.	1: preg	2: plas	3: pres	4: skin	5: insu	6: mass	7: pedi	8: age	9: class
	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Numeric	Normal
1	10.0	115.0	0.0	0.0	0.0	35.3	0.134	29.0	tested..
2	7.0	100.0	0.0	0.0	0.0	30.0	0.484	32.0	tested..
3	7.0	105.0	0.0	0.0	0.0	0.0	0.305	24.0	tested..
4	2.0	84.0	0.0	0.0	0.0	0.0	0.304	21.0	tested..
5	0.0	131.0	0.0	0.0	0.0	43.2	0.27	26.0	tested..
6	2.0	74.0	0.0	0.0	0.0	0.0	0.102	22.0	tested..
7	2.0	87.0	0.0	23.0	0.0	28.9	0.773	25.0	tested..
8	11.0	135.0	0.0	0.0	0.0	52.3	0.578	40.0	tested..
9	7.0	119.0	0.0	0.0	0.0	25.2	0.209	37.0	tested..
10	3.0	141.0	0.0	0.0	0.0	30.0	0.761	27.0	tested..
11	0.0	138.0	0.0	0.0	0.0	36.3	0.933	25.0	tested..
12	2.0	146.0	0.0	0.0	0.0	27.5	0.24	28.0	tested..
13	0.0	167.0	0.0	0.0	0.0	32.3	0.839	30.0	tested..
14	1.0	180.0	0.0	0.0	0.0	43.3	0.282	41.0	tested..
15	0.0	117.0	0.0	0.0	0.0	33.8	0.932	44.0	tested..
16	3.0	116.0	0.0	0.0	0.0	23.5	0.187	23.0	tested..
17	13.0	129.0	0.0	30.0	0.0	39.9	0.569	44.0	tested..
18	0.0	94.0	0.0	0.0	0.0	0.0	0.256	25.0	tested..
19	2.0	99.0	0.0	0.0	0.0	22.2	0.108	23.0	tested..
20	0.0	141.0	0.0	0.0	0.0	42.4	0.205	29.0	tested..
21	2.0	119.0	0.0	0.0	0.0	19.6	0.832	72.0	tested..
22	8.0	120.0	0.0	0.0	0.0	30.0	0.183	38.0	tested..
23	0.0	145.0	0.0	0.0	0.0	44.2	0.63	31.0	tested..
24	3.0	80.0	0.0	0.0	0.0	0.0	0.174	22.0	tested..

Add instance

Undo

OK


Cancel

Hice **doble clic izquierdo en 3: pres** ya que esa columna de datos mide la presión de las personas y haciendo esa acción **hace que los datos se ordenen de menor a mayor**, para así poder ver cuales son las filas de datos que tiene la presión cero y así eliminarlas.


Paso 6: Eliminamos las filas que contienen presión igual a **0.0**

Viewer														
Instance: prima diabetes														
No.	1: preg	2: plas	3: pres	4: skin	5: insu	6: mass	7: pedi	8: age	9: class					
Instance	Instance	Instance	Instance	Instance	Instance	Instance	Instance	Instance	Instance					
1	10.0	115.0	0.0	0.0	0.0	35.3	0.134	29.0	tested..					
2	7.0	100.0	0.0	0.0	0.0	30.0	0.404	32.0	tested..					
3	7.0	105.0	0.0	0.0	0.0	0.305	24.0	tested..						
4	2.0	84.0	0.0	0.0	0.0	0.304	21.0	tested..						
5	0.0	131.0	0.0	0.0	0.0	43.2	0.27	26.0	tested..					
6	2.0	74.0	0.0	0.0	0.0	0.102	22.0	tested..						
7	2.0	87.0	0.0	23.0	0.0	28.9	0.773	25.0	tested..					
8	11.0	135.0	0.0	0.0	0.0	52.3	0.578	40.0	tested..					
9	7.0	119.0	0.0	0.0	0.0	25.2	0.209	37.0	tested..					
10	3.0	141.0	0.0	0.0	0.0	30.0	0.761	27.0	tested..					
11	0.0	138.0	0.0	0.0	0.0	36.3	0.933	25.0	tested..					
12	2.0	146.0	0.0	0.0	0.0	27.5	0.24	28.0	tested..					
13	0.0	167.0	0.0	0.0	0.0	32.3	0.839	30.0	tested..					
14	1.0	180.0	0.0	0.0	0.0	43.3	0.282	41.0	tested..					
15	0.0	117.0	0.0	0.0	0.0	33.8	0.932	44.0	tested..					
16	3.0	116.0	0.0	0.0	0.0	23.5	0.187	23.0	tested..					
17	13.0	129.0	0.0	30.0	0.0	39.9	0.569	44.0	tested..					
18	0.0	94.0	0.0	0.0	0.0	0.0	0.256	25.0	tested..					
19	2.0	99.0	0.0	0.0	0.0	22.2	0.108	23.0	tested..					
20	0.0	141.0	0.0	0.0	0.0	42.4	0.205	29.0	tested..					
21	2.0	119.0	0.0	0.0	0.0	19.6	0.832	72.0	tested..					
22	8.0	120.0	0.0	0.0	0.0	30.0	0.183	38.0	tested..					
23	0.0	145.0	0.0	0.0	0.0	44.2	0.63	31.0	tested..					
24	3.0	80.0	0.0	0.0	0.0	0.0	0.174	22.0	tested..					
25	6.0	114.0	0.0	0.0	0.0	0.0	0.189	26.0	tested..					
26	4.5	91.0	0.0	0.0	0.0	20.8	0.301	31.0	tested..					
27	4.0	123.0	0.0	0.0	0.0	32.9	0.102	21.0	tested..					
28	2.0	74.0	0.0	0.0	0.0	21.1	0.342	25.0	tested..					
29	0.0	117.0	0.0	0.0	0.0	23.7	0.19	20.0	tested..					
30	0.0	117.0	0.0	0.0	0.0	26.4	0.212	36.0	tested..					
31	0.0	117.0	0.0	0.0	0.0	32.4	0.141	24.0	tested..					
32	0.0	117.0	0.0	0.0	0.0	26.0	0.61	31.0	tested..					
33	0.0	117.0	0.0	0.0	0.0	25.9	0.283	22.0	tested..					
34	0.0	117.0	0.0	0.0	0.0	36.5	0.304	41.0	tested..					
35	0.0	117.0	0.0	0.0	0.0	0.0	0.203	35.0	tested..					
Delete ALL selected instances					25.0	27.8	0.559	21.0	tested..					
Insert new instance														
Undo														
Copy														
Search...														
Clear search														
Delete selected instance														
Delete ALL selected instances														
Insert new instance														


Paso 7: Guardamos presionando **ok** y ahora volvemos hacer todo lo anterior para que el programa ahora si analice con datos coherentes.




Paso 8: Volvemos a poner la opción de estudiar 80% de los datos



Paso 9: Le damos a “start” y visualizamos una nueva matriz de confusión



Paso 10: Ahora seguimos los mismo pasos para visualizar el nuevo árbol de decisión de los datos limpios.



Paso 11: Sacamos nuestras interpretaciones y conclusiones:

Al inicio, el árbol estaba todo enredado y gigante porque los datos falsos de presión en cero lo hacían confundían. Esto obligaba al programa a inventar un montón de ramas y caminos para intentar adivinar el resultado.

Cuando borramos a los "muertos", gente con presión cero, el árbol dio un cambio total y se volvió mucho más limpio y lógico.

Cambios importantes:

- **La Glucosa manda, pero con mejor puntería:** En ambos árboles, la glucosa "plas" es lo más importante para saber si alguien tiene diabetes. Pero en el árbol limpio, el programa descubrió que el número clave de verdad es 143. Si el paciente pasa de 143 de glucosa, el árbol ya lo marca directo como positivo "diabético". Esto tiene sentido en la medicina real.
- **El camino de los sanos es más fácil:** En el árbol corregido, si un paciente tiene la glucosa baja " ≤ 143 " y además no tiene sobrepeso "masa corporal ≤ 26.3 ", el programa lo manda directo a negativo "sano".

En conclusión, hacer limpieza de los datos incoherentes fue la mejor decisión. Aunque la precisión general vario pero solo poco, logramos que el árbol de decisión sea mucho más corto, fácil de entender y con reglas que tienen lógica en la vida real.

Y la precisión tuvo una pequeña disminución (del 75.97% al 74.83%)